

Statistická analýza kognitivní efektivity: Člověk vs. Umělá inteligence (LLM) v úlohách mentální rotace v 2D

Účastníci: Danil Zyryanov, Kirill Ussov, Kamoliddin Bakhridinov

1. Úvod a Cíl

Cílem tohoto projektu bylo porovnat výkonnost lidských účastníků (studentů VŠ) a moderních modelů umělé inteligence (rodina modelů Gemini) při řešení úloh prostorové představivosti, konkrétně mentální rotace.

Tato část projektu, kterou zpracoval Danil Zyryanov, se zaměřuje na test mentální rotace na ploše (2D), kombinující prvky rotace a pattern matchingu.


Hlavní výzkumná otázka zněla: "Existuje statisticky významný rozdíl v efektivitě řešení prostorových úloh mezi člověkem a nejmodernějšími LLM modely?"

Byla stanovena nulová hypotéza (H_0): Mezi kognitivní efektivitou ((Přesnost (Accuracy) – Chybovost (Error Rate)) / Čas řešení (Time)) studentů VŠ a modelů Google AI neexistuje statisticky významný rozdíl.

Byla stanovena alternativní hypotéza (H_A): Mezi kognitivní efektivitou ((Přesnost (Accuracy) – Chybovost (Error Rate)) / Čas řešení (Time)) studentů VŠ a modelů Google AI existuje statisticky významný rozdíl.

2. Metodika

2.1 Test



Test se skládá z 10 otázek s postupně narůstající složitostí (více barev a polí). Pro sběr dat byla využita platforma cognition.run.

Zdroj na test: <https://xaobvfzwnw.cognition.run>

Kromě samotných odpovědí byla sbírána demografická a kontextová data (věk, pohlaví, hodiny spánku, subjektivní energie) a přesný čas strávený nad každou úlohou. Součástí testu byly i tréninkové otázky pro pochopení principů rotace.

U AI byli posbírané data: odpovědi a čas za každou úlohu.
Byl použit nástroj API.

Byl využit prompt:

- Practice 1:
You are participating in a mental rotation cognitive test. Look at the image provided. The 'TEST' square shows a pattern. Only ONE of the options (A, B, or C) is a valid rotation of the TEST pattern. Analyze the grid, corners, and color sequences carefully. MANDATORY: Return ONLY the letter (A, B, or C) as your answer. First question is a practice: Q: Which of these images (A, B, C) is a 90° clockwise rotation of the TEST image?
- Practice 2:
Second question is a practice: Q: Which of these images (A, B, C) is a 180° clockwise rotation of the TEST image? Look at the image provided. The 'TEST' square shows a pattern. Only ONE of the options (A, B, or C) is a valid rotation of the TEST pattern. Analyze the grid, corners, and color sequences carefully. MANDATORY: Return ONLY the letter (A, B, or C) as your answer.
- Reální test:
Q: Which of these images (A, B, C) is a rotation of the TEST image? You are participating in a mental rotation cognitive test. Look at the image provided. The 'TEST' square shows a pattern. Only ONE of the options (A, B, or C) is a valid rotation of the TEST pattern. Analyze the grid, corners, and color sequences carefully. MANDATORY: Return ONLY the letter (A, B, or C) as your answer at the end of your message.

2.2 Sběr dat

Do analýzy byly zahrnuty čtyři skupiny subjektů:

1. Human (Studenti): N=10. Reální účastníci řešící sadu testů.
2. AI Gemini 3 (Pro & Flash): N=8. Skupina "State-of-the-Art" modelů, které reprezentují současný vrchol technologie. Tato skupina byla použita pro hlavní statistické srovnání.
3. AI Gemini 2.5: N=4. Starší generace modelu.
4. AI Robotics: N=2. Specializovaný rychlý model.

2.3 Metrika: Čistá efektivita (Net Efficiency)

Pro objektivní srovnání nebyl použit pouze čas nebo pouze přesnost, ale kombinovaná metrika Net Efficiency, která penalizuje náhodné tipování.

Net Efficiency = (Přesnost (Accuracy) – Chybovost (Error Rate)) / Čas řešení (Time)

Pokud model odpovídá náhodně (přesnost $\leq 50\%$), efektivita klesá k nule nebo záporných hodnot. Tato metrika zamezuje tomu, aby "rychlé, ale chybující" modely (jako Robotics) získaly neoprávněnou výhodu.

3. Výsledky analýzy

3.1 Statistické srovnání (Mann-Whitney U test)

Byl proveden finální test na očištěných datech (vyloučení účastníci s náhodnými odpověďmi).

- Průměrná efektivita (Human): 0.0131 (bodů/sekundu)
- Průměrná efektivita (AI Gemini 3): 0.0089 (bodů/sekundu)
- P-value: 0.515


3.2 Interpretace

Hodnota p-value (0.515) je výrazně vyšší než hladina významnosti $\alpha = 0.05$.

To znamená, že přijímáme nulovou hypotézu (H_0).

Ačkoliv lidští účastníci dosáhli vyšší průměrné efektivity, vysoká variabilita (rozptyl) lidského výkonu způsobuje, že tento rozdíl není statisticky významný. Z hlediska statistiky dosahují modely Gemini 3 a studenti srovnatelné úrovně kognitivní efektivity.

5. Závěr



Experiment přinesl klíčové zjištění: V úlohách 2D mentální rotace dosáhla umělá inteligence (Gemini 3) úrovně lidské kognitivní efektivity.

Grafická analýza (Boxplot) ukazuje zajímavý trend:

1. Lidé mají vyšší "strop" výkonu – nejlepší studenti jsou stále efektivnější než nejlepší pokusy AI.
2. AI (Gemini 3) je však stabilnější (menší rozptyl) a spolehlivě překonává podprůměrný lidský výkon.
3. Starší modely (Gemini 2.5, Robotics) skončily se zápornou efektivitou, což dokazuje masivní technologický skok mezi generacemi modelů.

Celkově lze konstatovat, že pro tento typ úloh nastala éra parity (rovnosti) mezi průměrným člověkem a SOTA modely umělé inteligence.